

KHALIDOU SOGNANE

Data Engineer and IA

✉ khalidousognane@gmail.com

76 962 41 72

📍 Dakar / Thiès

[portfolio](#)

Ingénieur en fin de Master 2 (IA & Data, Université Iba Der Thiam), j'ai conçu de bout en bout un système RAG multimodal et un agent IA pour l'éducation — de l'ingestion des données jusqu'à l'évaluation par métriques RAG. Je maîtrise la chaîne complète : pipelines ETL/ELT, vectorisation sémantique, orchestration LLM, et déploiement API. Major de promo en M1. Je cherche à mettre ces compétences au service d'une équipe qui construit des produits IA à fort impact.

EXPÉRIENCE & PROJETS

Conception d'un système RAG multimodal + Agent IA

2024 – 2026

Mémoire de Master 2 · Université Iba Der Thiam, Thiès · Mention Bien

- Architecturé un pipeline RAG end-to-end : extraction PDF/images (PyMuPDF), chunking sémantique, vectorisation (FAISS / ChromaDB), retrieval et génération via LLM (Ollama + LangChain)
- Éliminé les hallucinations factuelles en ancrant les réponses sur des sources officielles vérifiées — évalué avec métriques NDCG, MRR, Faithfulness et Answer Similarity
- Intégré un module VLM (verbalisation d'images) pour rendre le système multimodal sur des corpus de cours Histoire-Géographie collège
- Déployé une API FastAPI exposant les endpoints de l'agent IA ; pipeline ETL/ELT automatisé avec Airflow

Projet Big Data Streaming – Application Taxi

2024

Projet académique · PySpark, Kafka, NiFi, Elasticsearch, Kibana

- Conçu le backend temps réel d'estimation de distance et de prix de trajet : ingestion Kafka → transformation NiFi → indexation Elasticsearch
- Visualisation live des flux dans Kibana ; pipeline tolérant aux pannes avec gestion des offsets

Analyse des trajets Citibike NYC

2024

Projet académique · PySpark, AWS EMR / S3, Hue

- Exploité +10 M de trajets réels (NYC, 2016) sous PySpark sur cluster EMR : volumes par mois/jour/station, durées moyennes, pics d'utilisation
- Produit des visualisations exploitables pour identifier les stations sous-capacitaires

Prédiction de risques cardiovasculaires

2023

Projet académique · Scikit-learn, Python

- Comparé régression logistique, Random Forest et SVM sur données médicales réelles ; Random Forest retenu — meilleure précision sur classe minoritaire

Tuteur & Assistant universitaire

2021 – 2023

Université Assane Seck de Ziguinchor

- Encadrement de nouveaux étudiants (inscriptions, orientation) et animation de tutoriels Algorithmique & Programmation

COMPÉTENCES TECHNIQUES

LLM & IA Générative : LangChain, Hugging Face, Ollama, RAG, Agents IA, Prompt Engineering, Fine-tuning, Transformers, VLM

ML / DL : Scikit-learn, TensorFlow, PyTorch, Keras · CNN, RNN, LSTM, GNN, Transfer Learning

Langages : Python, SQL, Java

Data Engineering : PySpark, Kafka, Apache NiFi, Airflow, Hadoop, AWS (S3, EMR)

Bases de données : PostgreSQL, MySQL, MongoDB, FAISS, ChromaDB, Elasticsearch

BI & Visu : Power BI, Looker Studio, Kibana, Dash, Matplotlib, Seaborn

FORMATION

Master 2 – Ingénierie des Données & IA

2024 – 2026

*Université Iba Der Thiam, Thiès · Mention Bien***Master 1 – Science des Données**

2023 – 2024

*Université Iba Der Thiam, Thiès · Major de promotion***Certificat Data Analysis**

Mai 2024

Licence MPI – Spécialité Informatique

2019 – 2023

*Université Assane Seck, Ziguinchor · Major de promotion L3***Baccalauréat S2**

2019

LANGUES

Français Courant (langue d'enseignement)**Anglais** Intermédiaire (lecture technique)**Wolof / Peul** Courant

SOFT SKILLS

- Rigueur analytique et sens du détail
- Autonomie et esprit d'initiative
- Travail en équipe et communication claire
- Capacité d'apprentissage rapide
- Gestion de projets complexes multi-étapes

Rigueur